Správa k projektu z predmetu BI-VWM.21

Názov projektu

Filmový odporúčací systém (Collaborative Filtering)

Členovia tímu

- Matej Hric
- Diana Sichanhová

1. Popis projektu

1.1 Cieľ projektu

Cieľom projektu bolo navrhnúť a implementovať webovú aplikáciu pre odporúčanie filmov na základe kolaboratívneho filtrovania (collaborative filtering). Systém analyzuje hodnotenia filmov od viacerých používateľov, identifikuje podobných používateľov a na základe ich hodnotení predikuje, ktoré filmy by sa mohli páčiť danému používateľovi.

1.2 Vstupy

- Reálny dataset MovieLens 100K — 943 používateľov, 1 682 filmov, 100 000 hodnotení na škále 1–5
- Hodnotenia filmov od používateľov zadávané cez webové rozhranie (škála 1–5 hviezdičiek)
- Konfiguračné parametre algoritmu: typ podobnostnej metriky, počet podobných používateľov (n), konštanta κ, minimálny počet hodnotení pre zahrnutie do výpočtu

1.3 Výstupy

- Predikované hodnotenia filmov, ktoré používateľ ešte nehodnotil
- Zoznam odporúčaných filmov pre každého používateľa zoradený podľa priemerného hodnotenia
- Vypočítané hodnoty podobnosti medzi všetkými pármi používateľov
- Štatistiky o výpočtoch (čas výpočtu, počet spracovaných používateľov, počet vygenerovaných odporúčaní)

2. Spôsob riešenia

2.1 Kolaboratívne filtrovanie

Systém využíva prístup používateľsky orientovaného kolaboratívneho filtrovania (user-based collaborative filtering). Princíp spočíva v tom, že ak dvaja používatelia hodnotili filmy podobne v minulosti, pravdepodobne sa im budú páčiť podobné filmy aj v budúcnosti.

Postup výpočtu:

1. Pre každý pár používateľov sa vypočíta miera podobnosti na základe spoločne hodnotených filmov.
2. Pre každého používateľa a každý nehodnotený film sa na základe hodnotení n najpodobnejších používateľov predikuje hodnotenie.

3. Filmy s najvyšším predikovaným hodnotením sa zobrazia ako odporúčania.

2.2 Podobnostné metriky

Spearmanova korelácia poradia

Spearmanova korelácia meria monotónny vzťah medzi hodnoteniami dvoch používateľov. Hodnotenia sa najprv prevedú na poradie (ranky) a následne sa vypočíta korelácia:

```
ρ = 1 - (6 × Σd²) / (n × (n² - 1))
```

kde:

- d = rozdiel poradia medzi hodnoteniami používateľov A a B pre rovnaký film
- n = počet spoločne hodnotených filmov

Výsledok je v rozsahu $\langle -1, 1 \rangle$. Je robustná voči extrémnym hodnoteniam a odľahlým hodnotám.

Kosínusová podobnosť

Kosínusová podobnosť meria uhol medzi vektormi hodnotení dvoch používateľov:

```
cos(θ) = (A · B) / (||A|| × ||B||)
```

kde:

- $A \cdot B$ = skalárny súčin vektorov hodnotení
- $||A||$, $||B||$ = euklidovské normy vektorov

Pearsonova korelácia

Pearsonova korelácia meria lineárnu závislosť medzi hodnoteniami dvoch používateľov:

```
r = Σ((x - x̄)(y - ȳ)) / √(Σ(x - x̄)² × Σ(y - ȳ)²)
```

kde:

- x, y = hodnotenia používateľov A a B pre spoločné filmy
- $\bar{x}$, $\bar{y}$ = priemerné hodnotenia používateľov A a B

Oproti kosínusovej podobnosti zohľadňuje priemernú úroveň hodnotení — kompenzuje skutočnosť, že niektorí používatelia hodnotia systematicky vyššie alebo nižšie.

2.3 Predikcia hodnotenia

Na výpočet predikovaného hodnotenia používateľa `a` pre film `j` sa používa vážený priemer odchýlok od priemeru:

```
p(a, j) = v̄(a) + κ × Σ w(a,i) × (v(i,j) − v̄(i)) / Σ |w(a,i)|
```

kde:

- `v̄(a)` = priemerné hodnotenie používateľa `a`
- `w(a,i)` = podobnosť medzi používateľmi `a` a `i`
- `v(i,j)` = hodnotenie používateľa `i` pre film `j`
- `v̄(i)` = priemerné hodnotenie používateľa `i`
- `κ` = konštanta škálovania (predvolená hodnota 1.0)

Výsledné predikované hodnotenie je ohraničené na interval ⟨1, 5⟩.

Podmienka pre zahrnutie dvojice používateľov do výpočtu: obaja musia mať aspoň `minRatedMoviesForSimilarity` hodnotení (predvolene 5) a spoločne hodnotené aspoň 2 filmy.

3. Implementácia

3.1 Programovacie jazyky

- **JavaScript (Node.js)** — serverová časť aplikácie
- **JavaScript (React 18)** — klientská časť aplikácie (SPA)
- **SQL** — dotazy na SQLite databázu

Backend pozostáva z Express.js servera s nasledujúcimi REST endpointmi:

- `POST /api/auth/register` — registrácia nového používateľa
- `POST /api/auth/login` — prihlásenie, vracia JWT token
- `GET /api/products` — zoznam filmov s vyhľadávaním, filtráciou (all / recommended / rated / unrated) a stránkovaním
- `GET /api/products/:id` — detail filmu vrátane hodnotenia prihláseného používateľa a priemerného hodnotenia
- `POST /api/ratings` — uloženie hodnotenia (upsert)
- `GET /api/recommendations` — odporúčania pre prihláseného používateľa (len nehodnotené filmy)
- `GET /api/admin/stats` — štatistiky databázy
- `GET/PUT /api/admin/config` — čítanie a ukladanie konfigurácie algoritmu
- `POST /api/admin/compute-similarities` — spustenie výpočtu podobností
- `POST /api/admin/compute-recommendations` — spustenie výpočtu odporúčaní

Frontend je Single Page Application v Reacte s týmito obrazovkami:

- Prihlásenie / Registrácia
- Prehľad filmov s vyhľadávaním, filtráciou a hodnotením hviezdičkami
- Odporúčania pre prihláseného používateľa
- Administrátorský panel (konfigurácia, štatistiky, spustenie výpočtov)

3.2 Databázová schéma

Aplikácia používa SQLite databázu s týmito tabuľkami:

- `users` — používatelia (id, username, password hash, email, is_admin)
- `products` — filmy (id, title, image_url, year, genre)
- `ratings` — hodnotenia (user_id, product_id, rating 1–5); unikátny pár (user_id, product_id)
- `user_similarities` — podobnosti medzi pármi používateľov (user_a_id, user_b_id, similarity, algorithm)
- `recommendations` — predikované hodnotenia (user_id, product_id, predicted_rating, algorithm)
- `config` — konfiguračné parametre algoritmu (key–value)

3.3 Dataset

Aplikácia je inicializovaná vlastným skriptom s reálnymi filmovými dátami:

- 943 používateľov s rôznymi žánrovými preferenciami
- 1682 filmov — reálne tituly s reálnymi IMDb skóre
- ~10 000 hodnotení generovaných na základe skutočného IMDb skóre každého filmu — populárnejšie filmy dostávajú vyššie hodnotenia
- Administrátorský účet: `admin` / `admin123`
- Používatelia: `ml_user_1` , `ml_user_2`, ... , `ml_user_943`/ `movielens123`

3.4 Použité knižnice

Backend:

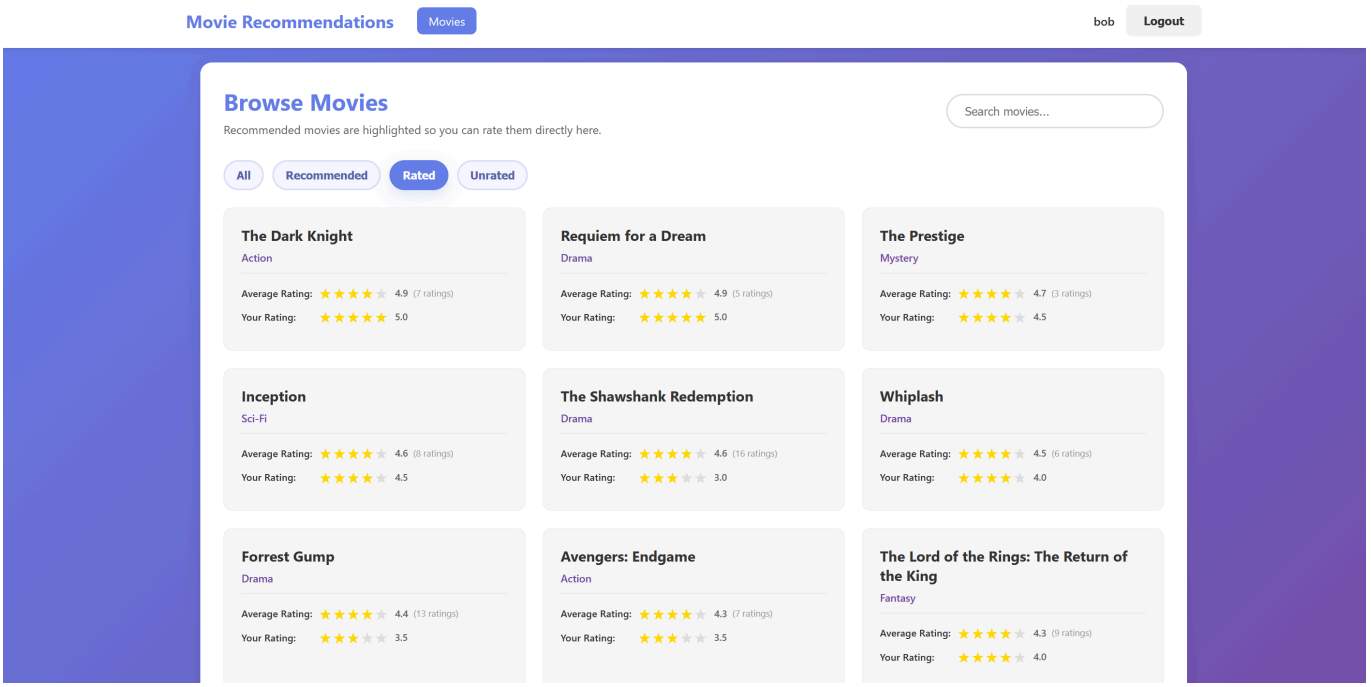
- `express` — HTTP server a smerovanie
- `better-sqlite3` — synchronný SQLite driver
- `jsonwebtoken` — JWT autentifikácia

Frontend:

- `react`, `react-dom` — UI framework
- `react-router-dom` — smerovanie v SPA

4. Príklady vstupu a výstupu

4.1 Hodnotenie filmov

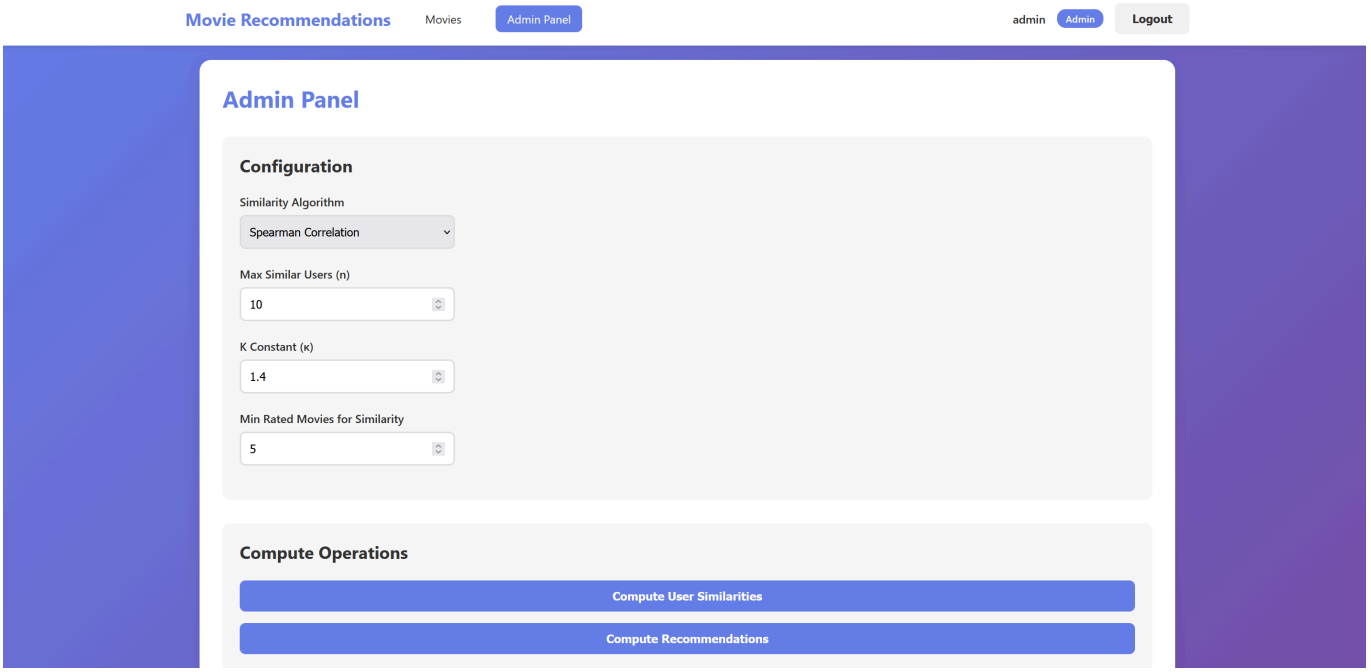


Používateľ prehliada zoznam filmov. Každý film zobrazuje žáner, priemerné hodnotenie všetkých používateľov a hodnotenie prihláseného používateľa. Hodnotenie sa zadáva kliknutím na hviezdičky (1–5) a je okamžite uložené do databázy.

Filmy je možné filtrovať podľa:

- **All** — všetky filmy
- **Recommended** — filmy odporúčané systémom (predikované hodnotenie > aktuálne priemerné)
- **Rated** — filmy, ktoré používateľ už hodnotil
- **Unrated** — filmy, ktoré používateľ ešte nehodnotil

4.2 Administrátorský panel — výpočet odporúčaní



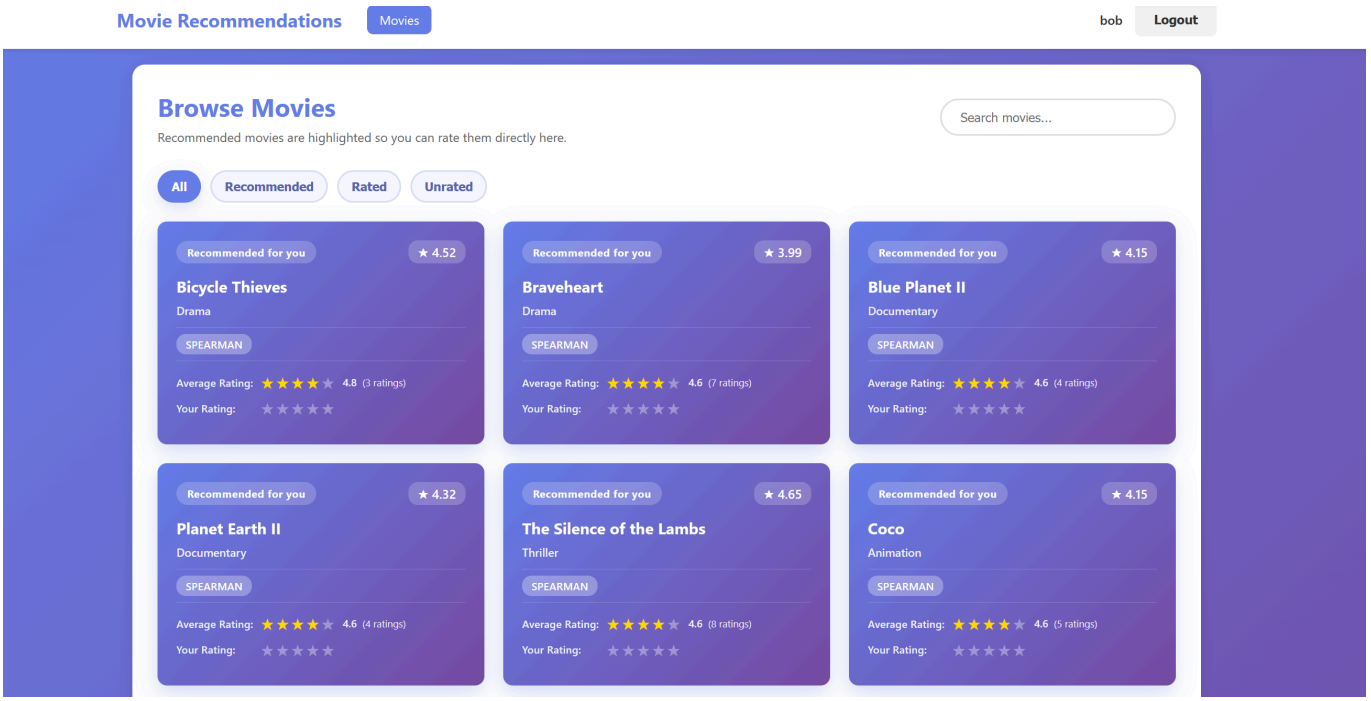
Administrátor nastaví parametre:

- **Similarity Algorithm**: Spearman / Pearson / Cosine

- **Max Similar Users (n)**: počet najpodobnejších používateľov zahrnutých do predikcie (predvolene 10)
- **K Constant (κ)**: koeficient škálovania predikcie (predvolene 1.0)
- **Min Rated Movies for Similarity**: minimálny počet hodnotení používateľa pre zahrnutie do výpočtu (predvolene 5)

Po stlačení „Compute User Similarities" a následne „Compute Recommendations" systém vypočíta a uloží predikované hodnotenia do databázy. Výsledok zobrazí počet spracovaných používateľov, počet vypočítaných podobností/odporúčaní a čas výpočtu.

4.3 Odporúčania pre používateľa



Na stránke prehľadu filmov sú odporúčané filmy vizuálne zvýraznené bannerom „Recommended for you" s predikovaným hodnotením a názvom použitého algoritmu. Odporúčania zahŕňajú iba filmy, ktoré používateľ ešte nehodnotil. Po ohodnotení filmu sa odporúčanie okamžite z bannera odstráni.

5. Diskuzia

Obmedzenia aktuálnej implementácie

Škálovateľnosť: Výpočet podobností prebieha sekvenčne v jednom vlákne Node.js s časovou zložitosťou $O(n^2)$. Pre stovky až tisíce používateľov by výpočet trval niekoľko minút. Riešením by bolo paralelizovanie pomocou Worker Threads, alebo presunutie výpočtov do výkonnejšieho prostredia.

Studený štart (Cold Start): Noví používatelia bez dostatočného počtu hodnotení nedostanú žiadne odporúčania. Riešením by bola kombinácia kolaboratívneho filtrovania s obsahovým filtrovaním (hybrid recommender), alebo onboarding proces, kde nový používateľ ohodnotí niekoľko filmov.

6. Záver

V rámci projektu sme navrhli a implementovali webovú aplikáciu pre odporúčanie filmov na základe kolaboratívneho filtrovania. Systém implementuje tri metriky podobnosti — Spearmanovu koreláciu, Pearsonovu koreláciu a kosínusovú podobnosť — a predikuje hodnotenia nehodnotených filmov váženým priemerom hodnotení podobných používateľov.

Aplikácia je inicializovaná reálnym datasetom MovieLens 100K a pozostáva z REST API backendu (Node.js/Express, SQLite) a React frontendu. Administrátorský panel umožňuje konfigurovať parametre výpočtu a spúšťať výpočty na požiadanie. Používatelia môžu hodnotiť filmy hviezdičkami a prehliadať personalizované odporúčania.